

Numérisation

1. Fréquence d'échantillonnage

Trop d'information → problème de stockage

Pas assez d'information → perte d'information

Trouver un compromis : **Théorème de Shannon**

$$F_e \geq 2 \times F_{\max}$$

Exemple :

Signal audio pleine bande à un spectre s'étalant de 20 Hz à 20 kHz

$$F_e \geq 40 \text{ kHz} \quad (= 2 \times 20 \text{ kHz})$$

Réduire le coût du traitement ou des données

→ limitation du spectre par **filtrage** (fréquence de coupure F_c)

Numérisation


1. Fréquence d'échantillonnage

Qualité	Spectre du signal F_{\max}	$F_e \geq 2 \times F_{\max}$	Applications
Téléphonique	200 - 3400 Hz	8 kHz	Téléphonie fixe
« Bande élargie »	50 - 7000 Hz	16 à 22 kHz	PC, audio- conférence (compression ADPCM)
Radiodiffusion	50 - 15000 Hz	32 kHz	DAB, NICAM (transmission son TV)
« Hi-Fi »	20 - 20000 Hz	44,1 à 48 kHz	CD Audio, Studio numérique, DAT

Numérisation

2. Quantification

Réduire la taille de l'ensemble des valeurs possibles des échantillons (qui peut être très grande)



Les valeurs de quantification sont espacées d'un **pas** (Q) :


- de taille fixe pour une quantification uniforme
- ou variable pour une quantification non-uniforme

Numérisation


2. Quantification

Ceci produit une **erreur de quantification** entre le signal source et le signal quantifié

Pour une quantification uniforme, on a une erreur de $Q/2$ (max)



Sur tout le signal on calcule l'erreur quadratique moyenne



Numérisation

4. Formats

Il existe de nombreux formats de fichiers son :

- .raw : fichier binaire nu (brut)
- .wav : introduit par Microsoft
- .aiff : utilisé sur Silicon Graphics et Macintosh
- .au : format SUN
- .mp3 : LE format d'échange (compressé)
- etc.

➔ encapsulent des informations complémentaires

Poids du fichier (bits/seconde)

Numérisation

✧ Exemples à écouter !

- ◆ De la parole et/ou de la musique
- ◆ Fichier original de parole : 16 bits, 16 kHz
- ◆ Variation de la fréquence d'échantillonnage

on arrive
plus à
comprendre
ce qui est
dit

↓
8 kHz
4 kHz
2 kHz

- ◆ Variation du nombre de bits de quantification

do + en
+ saturé ↓
8 bits
4 bits
2 bits

Numérisation

2. Quantification

Le pas de quantification Q dépend du **rapport signal à bruit**

(SNR = Signal to Noise Ratio)

Capacité à faire ressortir une information par rapport au bruit

↔ qualité d'une transmission d'information (valeur élevée = bonne qualité)

$$SNR_{dB} = 6,02b + 1,76dB$$

	Nombre de Bits	SNR _{dB}
Qualité « Hi-Fi »	16-18 bits	~ 95
Codage la parole, NICAM	14 bits	~ 80
Codage son PC	8 bits	~ 40

Intro SRI - Son

J. Pinquier

21

Numérisation

3. Codage

Après une quantification (= limitation du **nombre de bits** nécessaires pour stocker l'information)

Codage de l'information sur b bits :

→ 2^b valeurs possibles : de 0 à $2^b - 1$

1 bit : 2 valeurs 0, 1

2 bits : 4 valeurs 0, 1, 2, 3

8 bits : 256 valeurs de 0 à 255

Approximation des valeurs du signal continu en les ramenant à un ensemble réduit de valeurs

Exemple : codage sur 2 bits, des valeurs entières de 0 à 11

0 1 2 3 4 5 6 7 8 9 10 11 —
 0 1 2 3

Intro SRI - Son

J. Pinquier

22

Exercices

1- Calculer la taille mémoire d'1h d'un enregistrement en qualité téléphonique (8 bits, 8 kHz, mono).

Signal échantillonné à 8 kHz \Rightarrow 8000 val/s et $1h = 3600s$
Par 1h d'enregistrement $\Rightarrow 8000 \times 3600 = 28\,800\,000$ ~~val~~ échantillons
Codé sur 1 octet (8 bit) $\Rightarrow 28\,800\,000$ octets = 28,8 Mo

Exercices

2- Même question pour un enregistrement en qualité CD (16 bits, 44.1 kHz, stéréo).

Signal échantillonné à 44,1 kHz $\Rightarrow 44\,100$ val/s et $1h = 3600s$
Par 1h d'enregistrement $\Rightarrow 44\,100 \times 3600 = 158\,760\,000$ octets
Sur 16 bit ($\times 2$) } $158\,760\,000 \times 2 \times 2 = 635\,040\,000$ octets soit 635,04 Mo
stéréo ($\times 2$) }

Exercices

3- Quel est le débit (en bits/s) d'un signal en qualité studio (16 bits, 16 kHz) ?

$$\text{Fréquence} \times \text{Nb bit} \times \text{Nb piste} \\ 16000 \times 16 \times 1 = 256\,000 \text{ bit/s} = 256 \text{ kb/s} = 32 \text{ Ko/s}$$

Exercices

4- Si un ordinateur possède une connexion internet qui peut fonctionner à 100 ko/s, combien de temps sera nécessaire pour télécharger un fichier d'une heure qualité CD ?

$$\begin{aligned} &\hookrightarrow 16 \text{ bit}, 44,1 \text{ kHz}, \text{stéréo} \\ 44100 \text{ échantillons/s} \times 3600 \text{ par th} &\rightarrow 158\,760\,000 \text{ valeurs} \\ 2 \text{ pistes (2x)} &\rightarrow 317\,520\,000 \text{ valeurs codées sur 16 bits (2 octets)} \end{aligned}$$

Exercices

5- Si le signal suivant a été quantifié sur 5 bits, quelles sont les valeurs du signal numérisé ? 010111101000100

Handwritten solution for Exercise 5:

The binary sequence 010111101000100 is grouped into three 5-bit segments: 01011, 11101, and 00100. These are labeled 1, 2, and 3 respectively.

Below the sequence, the weights for 5-bit quantization are listed:

Bit Position	Weight
4	$2^4 = 16$
3	$2^3 = 8$
2	$2^2 = 4$
1	$2^1 = 2$
0	$2^0 = 1$

The binary sequence is then converted to decimal for each segment:

- Segment 1: 01011 → 11
- Segment 2: 11101 → 26
- Segment 3: 00100 → 4

Exercices

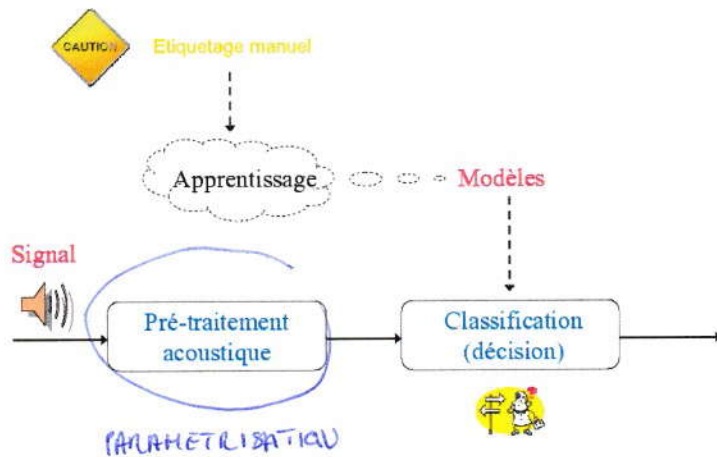
6- Quel est le rapport signal sur bruit en dB d'un signal DVD audio (24 bits 196 kHz) ?

$$SNR_{dB} = 6,02b + 1,76 \text{ dB}$$

$$b = 24 \rightarrow SNR_{dB} = 146,24$$

Mais, que faire ?

❖ Système classique de reconnaissance des formes



Intro SRI - Son


J. Pinquier

35


Mais, que faire ?

❖ Exemple : signal de parole

Représentation
temporelle



Représentation
temps/fréquence



Intro SRI - Son

J. Pinquier

36

Mais, que faire ?

✧ Pourquoi effectuer une paramétrisation ?

- ♦ CAR l'évolution temporelle du signal ne fournit pas directement les informations acoustiques

- ♦ zone voisée / non voisée

*énergie (= variance du signal stationnaire)
taux de passage à zéro (ZCR)*

- ♦ fréquence fondamentale (F_0)

calcul d'auto corrélation

- ♦ spectre (pour passer par les fréquences)

*décomposition du signal en une somme de sinusoïdes,
caractérisées chacune des amplitudes et sa fréquence
par son*

Mais, que faire ?

✧ Comment effectuer la paramétrisation ?

- ♦ CAR le signal de parole n'est pas stationnaire

- ♦ travailler sur des portions de signal et pas sur l'ensemble

- ♦ statistiques à court terme / statistiques à long terme

- ♦ fenêtres temporelles de 10 à 30 ms / plusieurs secondes

*généralement par du traitement de
détection de la langue*

- ♦ Spectre

Transformée de Fourier à court terme

TF Discrète (algorithme TF Rapide)


$$S(k) = \sum_{n=0}^{N-1} s(n) \cdot e^{-2i\pi k \frac{n}{N}}$$

- ♦ Spectrogramme

évolution à court terme du spectre de fréquence

Mais, que faire ?

✧ Avec un logiciel classique « wavesurfer »



Fréquence fondamentale
ou F_0 (pitch)

Spectrographe (formants)

) on peut potentiellement détecter
les voyelles avec les 2 premières fréq.

Energie / Intensité (dB)

Signal

Intro SRI - Son



J. Pinquier

39

Mais, que faire ?

✧ Analyse sur une fenêtre glissante

- Ordre de 20 ms
- Recouvrement (moitié en général)



Intro SRI - Son

J. Pinquier

40

Mais, que faire ?

✧ Quelques paramètres

- ◆ Temporels : Energie, ZCR
- ◆ Fréquentiels : issus de la DSP, coefficients spectraux
densité spectrale de puissance
- ◆ Autre : Mel Frequency Cepstrum Coefficients (MFCC)
Traitement complémentaire aux paramètres fréquentiels pour aller plus loin
- ◆ Etc.

Mais, que faire ?

✧ **Exercice** : soit un enregistrement sonore mono (1 piste), échantillonné à une fréquence de 16 kHz. L'analyse se fait sur des fenêtres de 256 points (avec recouvrement sur la moitié). *⇒ décalage de 128 points*

1. Quel est le nombre de points capturés par intervalle de temps ?
2. Quelle est la durée (en ms) d'une fenêtre d'analyse ?
3. Quel est le nombre de fenêtres (vecteurs) à traiter pour un fichier de 10 minutes ?

Mais, que faire ?

✧ Exercice (solution) :

1. Quel est le nombre de points capturés par intervalle de temps ?

$$16 \text{ kHz} \Leftrightarrow 16000 \text{ point/s}$$

2. Quelle est la durée (en ms) d'une fenêtre d'analyse ?

$$16000/256 \text{ points} \Leftrightarrow 256/16000 = 0,016 = 16 \text{ ms}$$

3. Quel est le nombre de fenêtres (vecteurs) à traiter pour un fichier de 10 minutes ?

$$\text{Durée : } 10 \text{ min} \Leftrightarrow 600 \text{ s}$$

$$\text{nb fenêtre (par s)} : 16000/256 \times 2 = 125$$

$$\text{Total : } 125 \times 600 = 75000 \text{ fenêtres}$$

Intro SRI - Son

\Rightarrow en réalité $75000 - 1 = 74999$ fenêtres
non \Rightarrow segmentation fault

43

Plan

✧ Introduction

✧ Paramétrisation générale

- ♦ Analyse temporelle
- ♦ Analyse fréquentielle
- ♦ Le cepstre
- ♦ Autres paramètres

✧ Paramétrisation spécifique

Intro SRI - Son

J. Pinquier

44



Analyse temporelle

pour normaliser (faire la moyenne)

nombre de point

✧ Energie : $E(t) = \frac{1}{N} \sum_{n=1}^N x_n^2(t)$ \equiv somme des amplitudes au carré

- ♦ Discrimination des sons voisés / non-voisés
- ♦ Détection de silence
- ♦ Aide à la décomposition en parole / musique



Intro SRI - Son

J. Pinquier

45



Analyse temporelle

renvoie 1 si $x > 0$
renvoie -1 si $x < 0$

✧ ZCR : $ZCR(t) = \frac{1}{2N} \sum_{n=1}^N |\text{sign}(x_n) - \text{sign}(x_{n-1})|$

- ♦ Plus discriminant que l'énergie

taille de la fenetre



Intro SRI - Son

J. Pinquier

46

signal -0,2 0,1 0,5 -0,4 -0,6 0,9

x_{n-1} x_n

$a = \text{sign}(x_{n-1})$ -1 1 1 -1 -1

$b = \text{sign}(x_n)$ 1 1 -1 -1 1

$|b-a|$ 2 0 2 0 2


$\frac{1}{2} \sum |b-a| = 3$

Analyse fréquentielle

✧ Spectre



♦ Signal x_n



Analyse fréquentielle

✧ Spectre



♦ Signal x_n

♦ Préaccentuation des aigus (\leftrightarrow filtre passe-haut)

$$H(z) = 1 - \alpha z^{-1} \text{ avec } \alpha = 0,98 \text{ en général}$$

Analyse fréquentielle

✧ Spectre



- ♦ Signal x_n
- ♦ Préaccentuation des aigus
- ♦ Fenêtrage

Analyse fréquentielle

✧ Fenêtrage : pourquoi ?

- ♦ Signal quasi-stationnaire sur fenêtres de 10 à 30 ms
- ♦ Pour limiter les effets de bord (réduire les discontinuités)

→ Pondération des ~~discontinuités~~ par fenêtre temporelle
aplatie aux extrémités

✧ Analyse sur une fenêtre glissante

→ Recouvrement (nécessaire en général)

✧ Exemples de fenêtres

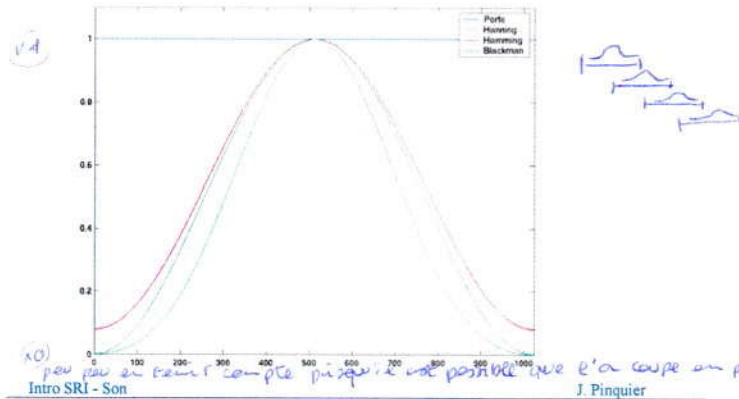
- ♦ Hamming → généralement utilisée en audio
- ♦ Hanning → généralement utilisée en image
- ♦ Triangulaire
- ♦ Rectangulaire

Analyse fréquentielle

✧ Fenêtre de Hamming

$$w(n) = 0,54 - 0,46 \cos\left(\frac{2\pi n}{N-1}\right), 0 \leq n \leq N-1$$

avec N : taille de la fenêtre en échantillons avec $N = 2^p$




53

Analyse fréquentielle

✧ Spectre



- ◆ Signal x_n
- ◆ Préaccentuation des aigus
- ◆ Fenêtrage de Hamming
- ◆ Transformée de Fourier Rapide




54

Analyse fréquentielle

✧ Impact de la longueur de la fenêtre d'analyse

- ♦ Bande étroite : fenêtre longue ($> F_0$) → *structure harmonique*
- ♦ Bande large : fenêtre courte ($< F_0$) → *structure formantique*



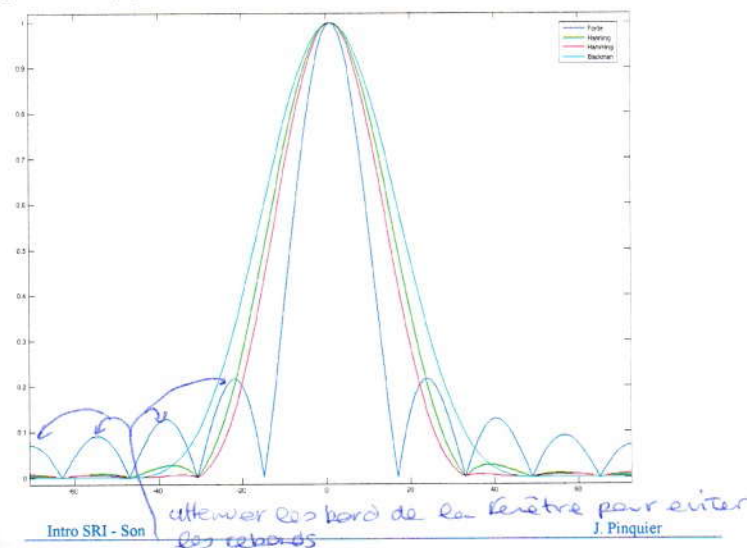
Intro SRI - Son

J. Pinquier

55

Analyse fréquentielle

✧ Impact du type de fenêtrage




Intro SRI - Son

J. Pinquier

56

Analyse fréquentielle

✧ Impact de la fenêtre de Hamming sur un spectre



57

Analyse fréquentielle

✧ Utilisation de la DSP (Densité Spectrale de Puissance)

- ◆ Transformée de Fourier de la fonction d'autocorrélation
- ◆ Paramètres de base

Centroïde spectral (centre de gravité)


$$C(t) = \frac{\sum_{n=1}^N \omega_n S_t(\omega_n)}{\sum_{n=1}^N S_t(\omega_n)}$$

pour déterminer c'est un signal basse freq, haute freq...

Flux spectral (variation du spectre)

$$FS(t) = \sum_{n=1}^N \left(\frac{S_t(\omega_n)}{\|S_t\|} - \frac{S_{t-1}(\omega_n)}{\|S_{t-1}\|} \right)$$

Spectral rolloff point (fréquence de coupure à 95%)







J. Pinquier

58

Analyse fréquentielle





Application : décomposition parole / musique

centroïde spectral







Intro SRI - Son

fluo spectral



spectral rolloff point




J. Pinquier

59

Analyse fréquentielle

Spectrogramme


évolution à court terme du spectre de fréquence



Intro SRI - Son

J. Pinquier

60




Plan

- ✧ Introduction
- ✧ Paramétrisation générale
 - ◆ Analyse temporelle
 - ◆ Analyse fréquentielle
 - ◆ Le cepstre
 - ◆ Exercices
- ✧ Paramétrisation spécifique

Le cepstre

✧ MFCC



- ◆ Préaccentuation des aigus
- ◆ Fenêtrage de Hamming
- ◆ Transformée de Fourier Rapide
- ◆ Utilisation de filtres triangulaires et de l'échelle MEL
- ◆ Log
- ◆ Transformée de Fourier Rapide discrète


Δ ce n'est pas
une transformée
inverse

Juste pour montrer
que d'on revient dans
le domaine temporel

Le cepstre

✧ Echelle perceptive

- ♦ Point de départ : la perception des sons de la parole des hautes fréquences est plus faible que celle des basses fréquences



Le cepstre

✧ Echelles perceptives

- ♦ **Echelle Mel** : linéaire en basse fréquence, logarithmique en haute fréquence

$$M = \frac{1000}{\log(2)} \log\left(1 + \frac{F}{1000}\right)$$

- ♦ **Echelle Bark** : $B = 6 \cdot \text{Arcsinh} \frac{F}{600}$

24 bandes critiques (Zwicker)

Le cepstre


✧ MFCC

- ◆ Déconvolution source/conduit = transformation homomorphique
séparer l'excitation du conduit vocal
supprimer la fréquence fondamentale (F_0)


$$\begin{aligned}
 S_n &= e_n \otimes c_n \\
 &\xrightarrow{\text{FFT}} \hat{S}_n = \hat{e}_n \times \hat{c}_n \quad \leftarrow \text{spectre} \\
 &\xrightarrow{\log} \log \hat{S}_n = \log \hat{e}_n + \log \hat{c}_n \\
 &\xrightarrow{\text{FFT} \rightarrow \log} \hat{\hat{S}}_n = \hat{\hat{e}}_n + \hat{\hat{c}}_n \quad \leftarrow \text{cepstre}
 \end{aligned}$$

Le cepstre

✧ Représentation du cepstre



Le cepstre



- ♦ $n_0 < 30 \rightarrow$ cepstre $[1: n_0]$
- ♦ 1^{er} coefficient, assimilé à l'énergie, souvent pas pris en compte

*Exemple : 12 MFCC + énergie $\Delta, \Delta\Delta$
→ 1 vecteur de 39 coefficients par fenêtre d'analyse*


Plan

- ✧ Introduction
- ✧ Paramétrisation générale
 - ♦ Analyse temporelle
 - ♦ Analyse fréquentielle
 - ♦ Le cepstre
 - ♦ Exercices
- ✧ Paramétrisation spécifique

Exercices

✧ Exercice 1

- ♦ Calculer la F_0 du cepstre ci-dessous sachant que $F_e = 16$ kHz et que la FFT a été réalisée sur 1024 points (fenêtre d'analyse de 1024 points)
- ♦ Homme ou femme ?
- ♦ Que vaudrait n_0 pour un enfant ($F_0 = 450$ Hz) ?



71

Exercices

✧ Exercice 1 : solution

- ♦ Calculer la F_0 de l'extrait ci-dessous sachant que $F_e = 16$ kHz et que la FFT a été réalisée sur 1024 points (fenêtre d'analyse de 1024 points)

$$n_0 = 105$$

$$F_e = 16 \text{ kHz} = 16000 \text{ points/s}$$

$$T_0 = 105 / 16000$$

$$F_0 = 1 / T_0 = 16000 / 105 = \underline{152 \text{ Hz}}$$

- ♦ Homme ou femme ?

Difficile à dire... Plutôt homme (cf cas précédent)

- ♦ Que vaudrait n_0 pour un enfant ($F_0 = 450$ Hz) ?


($n_0 < 30 \rightarrow$ enfant)

$$F_0 = \frac{n_0}{F_e} \Leftrightarrow n_0 = \frac{F_e F_0}{F_e} = \frac{16000 \times 450}{105} = 30$$

Intro SRI - Son

J. Pinquier


72



Exercices

✧ Exercice 2

- ♦ Calculer approximativement la valeur de la fréquence fondamentale en Hertz, sachant que la fréquence d'échantillonnage est de 16 kHz et que l'abscisse représente le numéro des échantillons
- ♦ Homme ou femme ? P_{ic1} P_{ic2}



73

Exercices

✧ Exercice 2 : solution

- ♦ Dédurre la valeur de la fréquence fondamentale en Hertz, sachant que la fréquence d'échantillonnage est de 16 kHz et que l'abscisse représente le numéro des échantillons

Par exemple $P_{ic1} = 360$ $P_{ic2} = 480$

Période en points (échantillons) : $480 - 360 = 120$

Période en temps : $120 / 16000 = 0,0075s$

Fréquence : $16000 / 120 = 133 Hz$

- ♦ Homme ou femme ?

A priori, un homme...

Intro SRI - Son

J. Pinquier

74

Exercices

✧ Exercice 3

- Écrire une fonction (en algorithme ou en Python) qui permette de calculer l'énergie à court terme d'un signal en fonction de la taille des fenêtres d'analyse, avec un recouvrement de moitié.

```
def energie(signal, taille_fenetre):
    # initialisation du vecteur resultat
    recouvrement = floor(taille_fenetre / 2)
    nb_fen = floor((np.size(signal) - taille_fenetre / recouvrement) + 1)
    # calcul de l'énergie
    # nbgz de 0 à (nb_fen - 1) par pas de 1
    nrg_res = np.zeros(nb_fen)
    for fen in range(nb_fen):
        p = fen * recouvrement
        nrg_res[fen] = np.sum((signal[p:p + taille_fenetre]) ** 2) / taille_fenetre
    return(nrg_res)
```

Exercices

✧ Exercice 4

- En s'inspirant de l'exercice 3, écrire une fonction qui permette de calculer le taux de passage par zéro (ZCR) en fonction de la taille des fenêtres d'analyse, avec un recouvrement de moitié.

```
def ZCR(signal, taille_fenetre):
    # initialisation du vecteur resultat
    recouvrement = floor(taille_fenetre / 2)
    nb_fen = floor((np.size(signal) - taille_fenetre / recouvrement) + 1)
    zcr_res = np.zeros(nb_fen)
    # calcul de la ZCR
    for fen in range(nb_fen):
        p = fen * recouvrement
        zcr_res[fen] = np.sum(np.abs(np.copysign(1, signal[p:p + taille_fenetre])
                                   - np.copysign(1, signal[p + taille_fenetre - 1:p + 2 * taille_fenetre]))) / (2 * taille_fenetre)
    return(zcr_res)
```


Introduction

❖ Spécificités de la musique : rappels

- ♦ Gamme 7 notes → DO RE MI FA SOL LA SI (DO)
- ♦ Octave 8 notes → ex: DO² - DO³ et rapport de freq: 2
- ♦ Quinte 5 notes → ex: DO - SOL et rapport de freq: 3/2
- ♦ Quarte 4 notes → ex: DO - FA et rapport de freq: 4/3
- ♦ L'étalon → le « LA3 » : 440 Hz

Introduction

❖ Spécificités de la musique : rappels

- ♦ Oreille humaine capte 10 octaves
- ♦ Gamme tempérée octave divisée en 12 intervalles (demi-tons)
demi-ton espacé de $2^{1/12} = 1,0595$
- ♦ Rapports de fréquences des notes

do	do#	ré	ré#	mi	fa	fa#	sol	sol#	la	la#	si	do
1	$2^{1/12}$	$2^{2/12}$	$2^{3/12}$	$2^{4/12}$	$2^{5/12}$	$\sqrt{2}$	$2^{7/12}$	$2^{8/12}$	$2^{9/12}$	$2^{10/12}$	$2^{11/12}$	2

Gamme tempérée			
Note	Fréquence	Rapport d'une note à l'autre	R
do ⁷	4186.01	2^{12}	
do ⁶	2093.02	2^{11}	
do ⁵	1046.51	2^{10}	
ré ⁴	523.25	2^9	1,0586
mi ³	440.00	2^8	1,0586
fa ²	369.99	2^7	1,0586
sol ¹	302.00	2^6	1,0586
la ⁰	246.98	2^5	1,0586
si ⁻¹	201.83	2^4	1,0586
do ⁻²	164.81	2^3	1,0586
ré ⁻³	131.85	2^2	1,0586
mi ⁻⁴	104.65	2^1	1,0586
fa ⁻⁵	83.72	2^0	1,0586
sol ⁻⁶	67.24	2^{-1}	1,0586
la ⁻⁷	53.98	2^{-2}	1,0586
si ⁻⁸	43.53	2^{-3}	1,0586
do ⁻⁹	35.00	2^{-4}	1,0586
ré ⁻¹⁰	27.93	2^{-5}	1,0586
mi ⁻¹¹	22.44	2^{-6}	1,0586
fa ⁻¹²	18.18	2^{-7}	1,0586
sol ⁻¹³	14.58	2^{-8}	1,0586
la ⁻¹⁴	11.65	2^{-9}	1,0586
si ⁻¹⁵	9.33	2^{-10}	1,0586
do ⁻¹⁶	7.47	2^{-11}	1,0586
ré ⁻¹⁷	5.98	2^{-12}	1,0586

Exercices

✧ Exercice 3

- Écrire une fonction (en algorithme ou en Python) qui permette de calculer l'énergie à court terme d'un signal en fonction de la taille des fenêtres d'analyse, avec un recouvrement de moitié.

def energie(signal, taille_fenetre):

```
#initialisation du vecteur resultat
recouvrement = floor(taille_fenetre/2)
nb_fen = floor((np.size(signal) - taille_fenetre / recouvrement) + 1)
# calcul de l'énergie
nrg_res = np.zeros(nb_fen)
for fen in range(nb_fen):
    p = fen * recouvrement
    nrg_res[fen] = np.sum((signal[p:p+taille_fenetre])**2) / taille_fenetre
return(nrg_res)
```

Handwritten notes:
 - "navigation de (0) à (nb_fen-1) par pas de 1" (next to nb_fen)
 - "somme de..." (next to np.sum)
 - "au carré" (next to **2)
 - "2 / taille_fenetre" (next to / taille_fenetre)

Exercices

✧ Exercice 4

- En s'inspirant de l'exercice 3, écrire une fonction qui permette de calculer le taux de passage par zéro (ZCR) en fonction de la taille des fenêtres d'analyse, avec un recouvrement de moitié.

def ZCR(signal, taille_fenetre):

```
#initialisation du vecteur resultat
recouvrement = floor(taille_fenetre/2)
nb_fen = floor((np.size(signal) - taille_fenetre / recouvrement) + 1)
zcr_res = np.zeros(nb_fen)
# calcul de la ZCR
for fen in range(nb_fen):
    p = fen * recouvrement
    zcr_res[fen] = np.sum(np.abs(np.copysign(-1, signal[p:p+taille_fenetre])
    - np.copysign(1, signal[p+taille_fenetre-1:])))) / (2 * taille_fenetre)
return(zcr_res)
```

Handwritten notes:
 - "calcul de la ZCR" (next to # calcul de la ZCR)
 - "2 * taille_fenetre" (next to / (2 * taille_fenetre))


Introduction

❖ Spécificités de la musique : rappels

♦ Nomenclature

A = LA B = SI C = DO D = RE E = MI F = FA et G = SOL

♦ Exemple : piano



Intro SRI - Son

J. Pinquier

81


Introduction

❖ Spécificités de la musique

♦ En musique, deux dimensions : note et octave

Exemple: MIDI A3 désigne un LA (A), 3^e octave. Une sinuséide de fréquence 440Hz donne une sensation de hauteur équivalente

♦ Représentation sous forme d'hélice Shepard [She64]



Intro SRI - Son

82

Introduction

❖ Spécificités de la musique : lien entre la fréquence F et la note de musique H

- ♦ Fréquence F exprimée en Hertz (Hz) -- échelle linéaire
- ♦ Hauteur perçue H -- échelle logarithmique

$$F = F_0 2^{\frac{H-H_0}{12}} \quad H = H_0 + 12 \log_2 \left(\frac{F}{F_0} \right)$$

avec H_0 et F_0 les hauteurs et les fréquences de référence

$$F_{\text{ref}} = F_0 = 440 \text{ Hz} \text{ et } H_{\text{ref}} = H_0 = 57$$

12 : nombre de dièses par octave

$$\text{Exemple : } F = 880 \text{ Hz} \Rightarrow H = 69$$

$F \times 2 \Rightarrow$ octave supérieure

$F/2 \Rightarrow$ octave inférieure

Intro SRI - Son

J. Piquier

83

Introduction

❖ Spécificités de la musique : variations de fréquence

- ♦ à l'échelle macroscopique : mélodie
- ♦ à l'échelle microscopique :

variations linéaires : glissando ou portamento

variations périodiques (< 20 Hz) : vibrato

variations périodiques plus rapides : rajout de composants spectraux

→ synthèse par modulation de fréquence (FM)

Intro SRI - Son

J. Piquier

84

Introduction


✧ Spécificités de la musique : spectre

- ♦ fréquences composant le son **régulièrement** espacées

→ la harmonique de fondamentale F_0

F_0 : fréquence **fondamentale** (ou première harmonique)

$k.F_0$: $k^{\text{ème}}$ harmonique



Intro SRI - Son

J. Pinquier

85

Plan

✧ Introduction

✧ Paramétrisation générale

✧ Paramétrisation spécifique

- ♦ Introduction
- ♦ **Fréquence fondamentale**
- ♦ Constant-Q Transform
- ♦ Chromas

Intro SRI - Son


J. Pinquier

86

Fréquence fondamentale

✧ Définition en parole

- ♦ F_0 : fréquence fondamentale de vibration des cordes vocales



Fréquence fondamentale


✧ Définition

- ♦ Correspond à la hauteur de la voix (mélodie)
- ♦ Intonation = *variation de F_0 ^{tens de}*
- ♦ Plage de valeur (en Hz) :
 - 80-250 : *homme*
 - 200-400 : *femme*
 - > 400 : *enfants*

liée à la taille des cordes vocales

Fréquence fondamentale

✧ Définition



Fréquence fondamentale

✧ Intérêts et fonctions

♦ Liée à l'accentuation : ~~Détection~~ Distinction entre harmoniques :
 "segment" (nom) ← EN → "segment" (verbe)

♦ De structuration
 phrase, discours : "la petite brise la glace"

♦ Modale
 Déclaration, interrogation, injonction, exclamative : "tu vas bien"

♦ Expressive
 Manifestation d'un sentiment
 Attitude

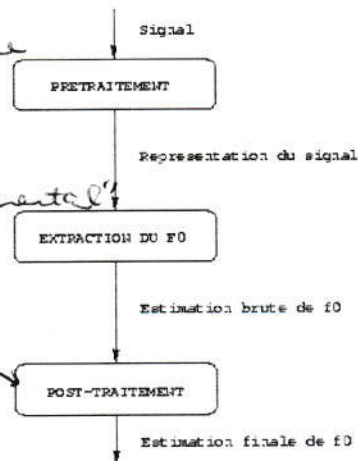
Fréquence fondamentale

✧ Extraction : principe général

*Un prétraitement acoustique
et un changement de
représentation*


l'extraction "brute" du fondamental

*Un post traitement pour
corriger les erreurs*



Fréquence fondamentale

✧ Extraction



♦ Autocorrélation [Hess83]

Algorithme de type « corrélation »

Hypothèse : le signal est stationnaire

$$F_{\text{Pautoc}} = \frac{1}{N} \sum_{n=0}^{N-1-\tau} s(n) s(n+\tau)$$

avec τ délai ou retard

$$\max \tau = T_0$$

Fréquence fondamentale

✧ Extraction

- ♦ Fonction de distance (AMDF) [Miller et Weibel 56]
critère de variation d'amplitude à court terme (Average Magnitude Difference Function)

$$FP_{AMDF}(\tau) = \sum_{n=0}^{N-1-\tau} |s(n) - s(n+\tau)|$$

Ambiguïté entre pics $T_0, 2 \cdot T_0 \dots$ atténuée par la non stationnarité du signal

Résiste aux erreurs grossières

Rapidité de calcul

Fréquence fondamentale

✧ Extraction


- ♦ Peigne spectral [Martin 81]
car deux espacé d'une distance quasi-constante

intercorrélation entre le spectre S du signal et un « peigne »

$\max FP \rightarrow F_0$

$$FP_{peigne}(f) = \sum_{i=1}^{n(f)} \alpha_i |S(i * f)|$$

Exemple
 $f = 110 \text{ Hz}$



Fréquence fondamentale

✧ Liens vers programmes classiques

- ♦ MES SignAix

http://www.lip.univ-aix.fr/en/projects/mes_signaix.html

- ♦ Snack/Wavesurfer

<http://www.speech.kth.se/wavesurfer/>

- ♦ Praat

<http://www.fon.hum.uva.nl/praat/>

- ♦ Modélisation automatique de la fréquence fondamentale F0 (MOMEL)

http://www.ics.utcn.fr/~soft/gut/mv_work/momel_french.html

- ♦ Snorri/WinSnorri

<http://www.loria.fr/~huet/>

YIN <https://audia-ens.fr/ade/> (travaille mieux)

Fréquence fondamentale

✧ Limite : la polyphonie (plusieurs notes jouées en même temps)

- ♦ Les méthodes précédentes sont dédiées à la monophonie

- ♦ Problème lié à la séparation de sources

- ♦ Problème très difficile

Sources sonores variées

Intervalle de notes possibles important

Musique : présence de batterie, de bruit

- ♦ Prise en compte du contexte tonal local

→ *Chorus au Pic Class Profile*

Plan

- ✧ Introduction
- ✧ Paramétrisation générale
- ✧ Paramétrisation spécifique
 - ◆ Introduction
 - ◆ Fréquence fondamentale
 - ◆ Constant-Q Transform
 - ◆ Chromas

Constant-Q Transform


- ✧ Signal de musique : choix de la fenêtre d'analyse est prépondérant !

- ◆ Fenêtre courte (bonne résolution temporelle)

→ Détecter des changements rapides du signal (attaques de note)

- ◆ Fenêtre grande

Distinguer des intervalles proches (hauteurs voisines)



Constant-Q Transform

✧ Illustration

- ♦ Soit un signal de musique avec 2 sinusoides de fréquences f_1 et f_2 qui correspondent à 2 notes adjacentes
- ♦ Notons $\Delta f = f_2 - f_1$
- ♦ Pour la musique occidentale (échelle logarithmique), les fréquences correspondant à 2 notes adjacentes sont d'autant plus proches que l'on se rapproche des basses fréquences
- ♦ 2 notes adjacentes (correspondant à un demi-ton) sont séparées par 6 % de la fréquence de la note la plus basse

Exemple : $f_{\text{Do1}} = 32,7 \text{ Hz}$ et $f_{\text{Do\#1}} = 32,7 \text{ Hz} + \overbrace{(0,06 \times 32,7)}^{6\%} = 34,6 \text{ Hz}$

Intro SRI - Son

J. Pinquier

101

Constant-Q Transform

✧ Solution : analyse fréquentielle multi-résolution

- ♦ Résoudre le dilemme résolution temps/fréquence

- ♦ FFT (transformée en résolution fixe)

fréquences espacées de manière égale (linéaire)
 \Rightarrow résolution fréquentielle constante

- ♦ Analyse fréquentielle multi-résolution

\Rightarrow Spectre de fréquences divisée en sous-bandes et chacune est traitée de manière indépendante

\hookrightarrow fenêtre courte pour les freq élevée
 \hookrightarrow fenêtre longue pour les freq faibles
 basse

Intro SRI - Son

J. Pinquier

102

Constant-Q Transform

✧ Transformée en constante Q (Constant-Q Transform – CQT)

- ♦ Proposée par Brown en 1991
- ♦ Canaux fréquentiels pas linéairement espacés (comme FFT)

MAIS géométriquement espacés : $Q = \frac{f}{\Delta f}$ est constant

avec f la fréquence centrale et Δf la résolution

freq centrales \rightarrow notes de musique accidentales

- ♦ Résolution temporelle augmente avec la fréquence
Basses fréquences : grande taille de fenêtre
Quand Fréquence augmente \rightarrow taille de fenêtre diminue

Constant-Q Transform

✧ Transformée en constante Q (Constant-Q Transform – CQT)

- ♦ Formule :

$$X(k) = \sum_{n=0}^{N(k)-1} w(n, k) x(n) e^{-j 2\pi F_k n}$$

avec :

- $X(k)$ la $k^{\text{ième}}$ composante de la CQT,
- $x(n)$ le signal,
- $w(n, k)$ la fenêtre d'analyse

La longueur de $w(n, k)$ à la fréquence f_k est : $N(k) = \frac{Q \cdot f_e}{f_k}$

avec $Q = \frac{f_k}{\Delta f_k}$ et f_e la fréquence d'échantillonnage


Constant-Q Transform

Transformée en constante Q (Constant-Q Transform – CQT)

Illustration

Taille de la fenêtre N (en secondes) en fonction de la fréquence (en Hertz)
pour un espacement d'un demi-ton ($Q = 2^{1/2} - 1$)


Exemple : 104 Hz \leftrightarrow 0,5 s



105

Constant-Q Transform

Transformée en constante Q (Constant-Q Transform – CQT)



Intro SRI - Son

J. Pinquier

106

Chromas

✧ Méthode

- Le spectre est divisé en 12 classes (12 demi-tons de la gamme)

le i^{e} coef du chroma vector correspond à l'énergie dans les bandes de freq correspondant à la i^{e} note de la gamme, à toutes les octaves possibles

- Intensité des 12 demi-tons

$$M(f_k) = \text{round}\left(12 \log\left(\frac{f_k}{f_{\text{ref}}}\right) \bmod 12\right)$$

- Vecteur de chromas (12 dimensions)

$$PCP(n) = \sum_k M(f_k) = n |X_k|^2 \text{ avec ou sans de carré}$$

- Normalisation possible

Intro SRI - Son


J. Pinquier

109

Chromas

✧ Chromagram

- Affichage compact de la représentation spectrale (FFT ou CQT)
- Exemple sur la gamme



Intro SRI - Son

110