

## EXAMEN D'ESTIMATION STOCHASTIQUE – 2ASRI

1<sup>o</sup> session – Mardi 13 Novembre 2018

Durée 1h30 – Tous documents de Cours, TD, TP autorisés – Tablettes et objets communicants interdits

**I. Questions de cours/** Répondre en trois phrases maximum, claires et convenablement construites, à chacune des questions suivantes. Les formules mathématiques seront particulièrement soignées.

1. Soient  $X \in \mathbb{R}^{n_X}$  et  $Y \in \mathbb{R}^{n_Y}$  deux vecteurs aléatoires continus,  $p_X(x)$ ,  $p_Y(y)$  leurs densités de probabilités respectives, et  $p_{X,Y}(x,y)$  leur densité de probabilité jointe. Rappeler le sens de  $p_X(x)$ ,  $p_Y(y)$ ,  $p_{X,Y}(x,y)$ . Citer, s'il y en a, les relations qui unissent ces lois.
2. Comment s'énonce un problème d'estimation en contexte classique (Fisher) ?
3. Soit  $p_{Z|\theta}(z|\theta)$  le modèle d'observation qui unit un vecteur de paramètres  $\theta \in \mathbb{R}^M$  déterministe inconnu au vecteur aléatoire de mesure  $Z \in \mathbb{R}^N$ , et soit  $I(\theta)$  la matrice d'information de Fisher associée. On désigne par  $\mathcal{N}(b, P)$  désigne la loi gaussienne multidimensionnelle d'espérance  $b$  et de matrice de covariance  $P$ . Que signifie le résultat suivant ?

(Sous certaines hypothèses de régularité,) lorsque  $N \rightarrow +\infty$ , l'estimateur du maximum de vraisemblance  $\hat{\theta}_{MLE}$  de  $\theta$  satisfait  $\hat{\theta}_{MLE} \sim \mathcal{N}(\theta, I^{-1}(\theta))$ .

**II. Synthèse d'un estimateur par maximum de vraisemblance/**

Étant donnée la séquence de scalaires réels  $x_1, \dots, x_N$ , on souhaite estimer deux constantes scalaires réelles inconnues  $a, b$  sur la base de  $N$  observations  $z_1, \dots, z_N$ , réalisations des variables aléatoires  $Z_1, \dots, Z_N$  liées à  $a, b$  et  $x_1, \dots, x_N$  par

$$\forall n = 1, \dots, N, \quad Z_n = ax_n + b + W_n \quad (1)$$

où  $W_1, \dots, W_N$  sont des variables aléatoires scalaires réelles i.i.d. selon la loi Gaussienne  $\mathcal{N}(0, \sigma^2)$  de moyenne nulle et de variance  $\sigma^2$  donnée. Un problème physique correspondant à cet énoncé mathématique consiste à établir une régression linéaire entre les  $N$  points de coordonnées  $\left\{ \begin{pmatrix} x_n \\ z_n \end{pmatrix} \right\}_{n=1, \dots, N}$ .

Répondre aux questions suivantes.

4. Reformuler le problème de façon à exprimer le vecteur d'observations  $z = (z_1, \dots, z_N)^T$  comme la réalisation d'un vecteur aléatoire  $Z = (Z_1, \dots, Z_N)^T$  lié au vecteur  $\theta = (a, b)^T$  des paramètres cachés par une équation linéaire avec bruits additifs de la forme

$$Z = H\theta + V, \quad (2)$$

en explicitant les expressions de la matrice déterministe  $H$  et du vecteur de bruits  $V$ .

5. Expliquer pourquoi  $V$  est Gaussien. Donner son espérance et sa matrice de covariance.
6. Écrire, sans la développer, l'expression de l'estimé du maximum de vraisemblance  $\hat{\theta}$  du vecteur  $\theta$ , obtenu pour une réalisation  $z$  du vecteur  $Z$ . On réutilisera autant que possible des résultats développés en cours.
7. Préciser à quelles conditions cet estimé peut être obtenu.
8. Développer ce calcul. On pourra éventuellement introduire les quantités suivantes :

$$\bar{x} = \sum_{n=1}^N x_n; \quad v_x = \frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})^2 = \left( \frac{1}{N} \sum_{n=1}^N x_n^2 \right) - \bar{x}^2; \quad (3)$$

$$\bar{z} = \sum_{n=1}^N z_n; \quad c_{xz} = \frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})(z_n - \bar{z}) = \left( \frac{1}{N} \sum_{n=1}^N x_n z_n \right) - \bar{x}\bar{z}. \quad (4)$$



9. Soient  $\hat{a}, \hat{b}$  (composantes de l'estimé  $\hat{\theta}$ ) les estimés de  $a, b$  (composantes de  $\theta$ ) obtenus pour un vecteur d'observations  $z$  (réalisation de  $Z$ ). On souhaite déterminer des intervalles de confiance autour de  $\hat{a}$  et  $\hat{b}$  dans lesquels se trouvent les paramètres cachés  $a, b$  avec une probabilité de 99.7%. Expliciter les étapes suivantes permettant d'obtenir ce résultat.

(a) Rappeler les statistiques de l'estimateur  $\hat{\Theta}$  :

- i. Expliquer pourquoi il est Gaussien.
- ii. Démontrer qu'est centré sur  $\theta$ .
- iii. Rappeler, *sans démonstration*, sur la base de résultats développés en cours, l'expression de sa matrice de covariance.

(b) En déduire les statistiques de l'erreur d'estimation  $\varepsilon = \theta - \hat{\Theta}$  :

- i. Montrer que cette variable (2D) est Gaussienne, centrée sur 0.
- ii. Développer autant que possible l'expression mathématique de sa matrice de covariance.
- iii. Déduire les expressions des lois Gaussiennes des erreurs d'estimation sur  $a$  et sur  $b$ .

(c) En déduire les intervalles de confiance recherchés.

Le paramètre  $b$  est désormais connu, de sorte que le vecteur des paramètres cachés s'écrit  $\theta = a \in \mathbb{R}$ .

10. Réécrire (2) sous la forme

$$Y = La + V, \quad (5)$$

où  $V$  est le vecteur aléatoire de bruit établi plus haut, et  $Y = (Y_1, \dots, Y_N)^T$  est un « nouveau » vecteur aléatoire de mesure dont on précisera le lien avec  $Z$ .

11. Écrire l'expression de l'estimé  $\hat{a}$  du maximum de vraisemblance de  $a$  dans ce nouveau contexte.

12. L'intervalle de confiance centré sur l'estimé  $\hat{a}$ , et dans lequel le paramètre caché  $a$  se trouve avec une probabilité de 99.7%, est-il de même taille que dans le cas précédent ? plus grand ? plus petit ?